

ARAŞTIRMA
MAKALESİ

Yapay Zeka Modelleriyle At Cerrahisi ve Hayatta Kalma Tahmini: Orijinal, İmputasyonlu, Dengelenmiş ve Özellik Seçilmiş Veri Setlerinin Performans Karşılaştırması

Pınar CİHAN^{1(*)} ¹ Tekirdağ Namık Kemal Üniversitesi, Çorlu Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü, TR-59860 Tekirdağ - TÜRKİYE

(*) Sorumlu yazar: Pınar CİHAN Telefon:

+90 282 250 2456

E-posta: pkaya@nku.edu.tr

Bu makaleye nasıl atıfta bulunulur?

Cihan P: Yapay zeka modelleriyle at cerrahisi ve hayatta kalma tahmini: Orijinal, imputasyonlu, dengelenmiş ve özellik seçilmiş veri setlerinin performans karşılaştırması. *Kafkas Univ Vet Fak Derg*, 30 (2): 233-241, 2024.

DOI: 10.9775/kvfd.2023.30908

Makale Kimliği: KVFD-2023-30908

Alındığı tarih: 12.10.2023

Kabul Tarihi: 03.01.2024

Çevrimiçi Yayınlanma Tarihi: 08.01.2024

Özet

Yapay zeka (AI) teknolojisi, insan tıbbına kıyasla daha az gelişmiş olsa da, veterinerlik alanında önemli bir potansiyele sahiptir. Bu teknoloji, hastalık teşhisi, tedavi planlaması, hastalık kontrolü ve genel hayvan sağlığının iyileştirilmesi gibi bir dizi önemli fayda sunmaktadır. Klinik verilere dayanan bu çalışma, akut karın ağrısı (kolik) belirtileri gösteren atlarda ameliyat gerekliliğini ve hayatta kalma olasılığını tahmin etmek için 15 yapay zeka modelini kullanmaktadır. Orijinal, eksik değerlerin doldurulduğu ve dengelenmiş veri kümeleri arasında cerrahi ve hayatta kalma tahminlerini karşılaştırarak, 15 AI modelinin ortalama doğruluğuna dayalı olarak en etkili veri kümesini belirliyoruz. Ayrıca, cerrahi ve hayatta kalma tahminleri için özellik önem puanlarını hesaplayarak, azaltılmış bir özellik kümesiyle doğruluğun artırılma potansiyelini araştırıyoruz. Sonuçlarımız, dengelenmiş veri kümesinin cerrahi ve hayatta kalma tahminlerinde sırasıyla %80,76 ve %77,96 ile en yüksek ortalama doğruluğu elde ettiğini göstermektedir. Random Forest (RF) modeli, hem cerrahi (doğruluk = 85,83, Eğri Altındaki Alan [AUC] = 0,906) hem de hayatta kalma tahmini (doğruluk = 80,75, AUC = 0,888) için en doğru model olarak diğerlerinden daha iyi performans gösterdi. Veri setindeki özellik sayısının %56 oranında azaltılmasının, ameliyat tahmin doğruluğunu %86,38'e çıkardığı gözlemlenmiştir. Benzer şekilde, hayatta kalma tahmini için özellik sayısı %24 oranında azaltıldığında, tahmin performansı %83,75'e yükselmiştir. Bu çalışma, model performansını önemli ölçüde artırabilen yapay zeka tekniklerinin veterinerlik tıbbında hassas bir şekilde uygulanmasının önemini vurgulamaktadır.

Anahtar kelimeler: Yapay zeka, Veri dengeleme, Özellik seçimi, At kolik, Tahmin, SMOTE

Giriş

Son yıllarda, yapay zeka alanındaki araştırmalar büyük ilgi görmüş ve kayda değer ilerlemeler kaydedilmiştir. Yapay zeka modelleri kullanılarak gerçekleştirilen en popüler görevler, tahmin/sınıflandırma^[1,2] ve regresyon problemleridir^[3,4]. Ancak, veterinerlik tıbbında bu teknolojinin kullanımı, diğer alanlarda olduğu kadar gelişmiş değildir. Bununla birlikte, veterinerlik tıbbında yapılan çalışmalar, bu teknolojiyle başarılı sonuçlar elde etme potansiyelini ortaya koymuştur^[5,6].

At sağlığı, yapay zeka teknolojisinin uygulanması gereken temel alanlardan biridir. Bunun nedeni, atların genellikle yarışlarda kullanılan değerli hayvanlar olmasıdır. Akut karın ağrısı (kolik), atlarda en sık karşılaşılan sağlık sorunlarından biridir. Kolik, atlar için ciddi bir sağlık

sorun oluşturur ve zamanında tedavi edilmezse ölüme yol açabilir. Bu sorun, önemli bir ekonomik etkiyle yakından bağlantılıdır ve at sahipleri için önemli bir endişe kaynağıdır^[6]. Atlarda kolik vakalarının yaklaşık %90'ı kendiliğinden veya tıbbi tedavi ile düzelir, ancak kalan %10'luk kısım cerrahi tedavi uygulanmazsa ölümcül olabilir^[7]. Bu nedenle veteriner hekimler, kolik belirtilerini tanıyarak ve hızlı müdahale sağlayarak atların sağlığını korumaya çalışmaktadır. İşte bu noktada, hızlı ve doğru tahminler sunan yapay zeka modelleri devreye girer ve veteriner hekimlerin karar verme süreçlerinde destekleyici bir araç olarak kullanılabilir.

Yapay zeka sistemleri matematiksel modellere dayanır ve örnek veriler kullanılarak eğitilmeleri gerekir. Bu eğitim verileri, modelin istenen çıktıları öğrenmesine yardımcı olan bilgileri içerir. Yapay zeka



bilgisayarların öğrenme, karar verme ve problem çözme yeteneklerini geliştirmek için kullanılır ve yeni modeller ve uygulamalar sürekli olarak geliştirilmektedir.

Yapay zeka, veterinerlik alanında vücut ağırlığı tahmini [8], tanısal radyoloji [9], kan numunesi değer tahmini [10], bulaşıcı ve enflamatuvar hastalıkların teşhisi [11], radyografilerin sınıflandırılması [12], hayvan teşhisi [13], süt verimi tahmini [14] ve kemik kırığı yerlerinin belirlenmesi [15] için kullanılmaktadır. WOS veritabanında “At koliki + yapay zeka”, “At koliki + makine öğrenimi” ve “At koliki + veri madenciliği” anahtar kelimeleri kullanılarak yapılan bir aramada, konuyla ilgili bir çalışma bulunmuştur. Bu çalışmada Fraiwan, yapay zeka yöntemlerini kullanarak kolikli atların ameliyat gerekliliğini ve hayatta kalma olasılığını sırasıyla %76 ve %85 doğruluk oranıyla tahmin etmiştir [6].

Bu çalışma, at kolikinde doğru cerrahi müdahale ve hayatta kalma tahminleri yapmayı amaçlamaktadır. Bu amaçla, çalışmada kullanılan veri kümesinde eksik değerler bulunmakta ve veri dağılımı dengesizdir. Veri kümesinin getirdiği zorlukları aşmak ve doğru tahminler elde etmek için yapay zeka metodolojisi titizlikle uygulanmış ve her aşamada tahmin sonuçları değerlendirilmiştir.


Bu çalışmanın temel katkıları şu şekilde özetlenebilir:

- Bu çalışma, missForest yöntemini kullanarak veri setindeki eksik değerleri doğru bir şekilde tamamlamanın tahmin performansını artırdığını göstermektedir.
- Bu çalışma, SMOTE yöntemini kullanarak veri dengesizliği sorununu ele almakta ve dengeli bir veri setinin tahmin performansını artırdığını ortaya koymaktadır.
- Çalışma, doğruluk ve AUC istatistiksel ölçütlerini kullanarak 15 yapay zeka modelinin performansını değerlendirir ve sonuç olarak RF modelinin diğer modellerden daha iyi performans gösterdiğini ortaya koyar.
- Çalışma, daha az özellik kullanılarak daha yüksek derecede cerrahi başarı ve hayatta kalma tahmininde doğruluk elde edilebileceğini göstermektedir.

MALZEME VE YÖNTEMLER

Sistem Mimarisi

Bu çalışma, kolik olan atlarda cerrahi müdahale ihtiyacını ve hayatta kalma olasılığını tahmin etmek için bir dizi adım uygulamıştır. Modellerden elde edilen sonuçlar, veri setine ve uygulanan süreç adımlarına göre değişebilir [16]. Bu nedenle, araştırmacılar veri setine ve ihtiyaçlara göre bu adımları azaltabilir veya artırabilir. Sınıflandırma sürecini gösteren akış şeması *Şekil 1’de* gösterilmiştir ve sonraki bölümlerde her aşama ayrıntılı olarak açıklanmaktadır.



Kullanılan Veri Seti

Bu çalışmada kullanılan veri kümesi çevrimiçi olarak herkese açıktır [17]. 299 atın tıbbi verilerini içeren veri kümesi, 27 özellikten oluşmaktadır; bunlardan 25’i girdi, ikisi ise çıktı olarak kullanılmaktadır. Çıktı olarak kullanılan “cerrahi” değişkeni, atların ameliyat geçirip geçirmediğini gösterir. Diğer çıktı değişkeni ise atın hayatta kalıp kalmadığına dair bilgileri içerir. *Tablo 1*, veri setindeki özelliklerin karakteristiklerini, türlerini, özellik bilgilerini, eksik değer istatistiklerini ve bunların yapay zeka modellerinde girdi/çıkıtı olarak kullanılmasına ilişkin bilgileri sunmaktadır.

Veri Dönüşümü

Veri dönüşümü, verileri veri kümesi analizi veya modellemeye daha uygun hale getirmek için değiştirme veya yeniden şekillendirme sürecidir [18]. Bu süreç, veri kalitesini artırır, daha iyi model performansı sağlar ve verilerin anlaşılabilirliğini geliştirir. Yaygın veri dönüşümü teknikleri arasında özellik ölçeklendirme, normalleştirme, kategorik verilerin dönüşümü ve aykırı değerlerin işlenmesi yer alır.

Bu çalışmada, veri kümesi kategorik veri dönüştürme teknikleri kullanılarak dönüştürülmüştür. Örneğin, normal, sıcak, serin ve soğuk değerlerine sahip ekstremita sıcaklığı özelliği, sırasıyla 0, 1, 2 ve 3 olarak dönüştürülmüştür. Tüm kategorik özellikler bu dönüşüme tabi tutulmuştur. Ayrıca, çalışma hayatta kalma durumunu tahmin etmeyi amaçladığından, hayatta kalan at örneklerine 0, ölen ve ötenazi uygulanan at örneklerine ise 1 değeri atanmıştır. Veri dönüşümünden sonra ameliyat ve hayatta kalma tahminleri için kullanılan veri setine *orijinal veri seti* adı verilmiştir.

Eksik Değerlerin Doldurulması

Bilimsel araştırmalarda, araştırmacılar beklenen parametrelerden sapma gösterebilen eksik veri toplama durumlarıyla karşılaşabilirler. Doldurma, eksik verileri doldurarak kullanılabilir hale getirmeyi amaçlayan popüler veri analizi yaklaşımlarından biridir [19]. Veri setinde eksik değerlerin bulunması, planlanan analiz için bir zorluk teşkil eder. Bunun nedeni, neredeyse tüm klasik ve çağdaş istatistiksel tekniklerin, veri setinin kapsamlı olduğu varsayımına dayalı olarak geliştirilmiş olmasıdır [20]. Bu çalışmada Cihan [20] ortalama, kNN, SVD, bPCA ve

Tablo 1. At Kolik veri setinin özellikleri ve bilgileri

Özellik	Tür	Özellik Bilgisi	#NA	Eksiklik Oranı	Yön
Yaş	Kategorik	Yetişkin, Genç (<6 ay)	0	0	giriş
Ekstremitelerin sıcaklığı		Normal, ılık, serin, soğuk	56	%19	
Periferik nabız		Normal, artmış, azalmış, yok	69	%23	
Mukoza zarları		normal pembe, parlak pembe, soluk pembe, soluk siyanotik, parlak kırmızı, koyu siyanotik	47	%16	
Kılcal damar dolum süresi		< 3 saniye, >= 3 saniye	32	%11	
Ağrı		Ağrı yok, depresif, hafif ağrı, şiddetli ağrı, aşırı ağrı	55	%18	
Peristaltizm		Hipermotil, normal, hipomotil, yok	44	%15	
Karın şişkinliği		Yok, hafif, orta, şiddetli	56	%19	
Nazogastrik tüp		Yok, hafif, belirgin	104	%35	
Nazogastrik reflü		Yok, > 1 litre, < 1 litre	106	%35	
Rektal muayene - dışkı		Normal, artmış, azalmış, yok	102	%34	
Karın		Normal, diğer, sert, ince bağırsak, kalın bağırsak	118	%39	
Abdominosentez görünümü		Berrak, bulanık, sero-kanlı	165	%55	
Cerrahi lezyon		Hayır: Cerrahi olmayan lezyon/Evet: Cerrahi lezyon	0	%0	
Cp_data		Hayır: Patoloji verisi mevcut değil/Evet: Veri mevcut	0	0	
Rektal sıcaklık	Sayısal	Min: 35,4 - Maks: 40,8	60	%20	giriş
Nazogastrik reflü pH		Min: 1 - Maks: 7,5	246	%82	
Nabız		Min: 30 - Maks: 184	24	%8	
Solunum hızı		Min: 8 - Maks: 96	58	%19	
Hematokrit		Min: 23 - Maks: 75	29	%10	
Toplam protein		Min: 3,3 - Maks: 89	33	%11	
Abdomsentez toplam protein		Min: 0,1 - Maks: 10,1	198	%66	
Lezyon_1		Min: 0 - Maks: 41110	0	0	
Lezyon_2		Min: 0 - Maks: 7111	0	0	
Lezyon_3		Min: 0 - Maks: 2209	0	0	
Cerrahi	Kategorik	Hayır: at ameliyat oldu/Evet: ameliyat olmadı	0	0	Çıktı
Sonuç (Hayatta kalma)	Kategorik	Yaşadı, Öldü, Ötenaziye Tabi Tutuldu	0	0%	çıkı

missForest imputasyon yöntemleri. Analiz, missForest yönteminin tüm farklı veri kümelerindeki eksik verileri başarıyla işlediğini ortaya koydu. Sonuç olarak, bu çalışmada horseColic veri kümesindeki eksik değerler missForest yöntemi kullanılarak imputasyon edildi.

MissForest yöntemi, eksik değerleri tahmin etmek için Random Forest'ı kullanır. Her eksik değişken için ayrı bir Random Forest modeli oluşturur. Bu modelleri, eksik değişkenler, diğer eksiksiz değişkenler ve çıktı değişkeni arasındaki ilişkileri dikkate alarak eksik değerleri tahmin etmek için kullanır ^[21]. Bu, eksik verilerin doğru ve güvenilir bir şekilde tamamlanmasına yardımcı olur. Bu yöntemi uygulamak için R programlamasındaki 'missForest' işlevi kullanılmıştır. Bu işlev, 'surgery' çıktı değişkenini içeren veri集中的 eksik değerleri ve ardından

"survive" çıktı değişkenini içeren veri setinde de eksik değerleri tamamladı. Bu çalışmada, missForest yöntemi kullanılarak eksik değerleri doldurulmuş veri seti versiyonuna "doldurulmuş veri seti" adı verilmiştir.

WEKA'da yapay zeka yöntemlerini uygularken, eksik değerler içeren veri setleriyle çalışabilirsiniz. WEKA, eksik verileri göz ardı eder ve bu örnekleri sınıflandırma veya yapay zeka süreçlerinde kullanmaz. Eksik verilerin göz ardı edilmesi, veri setinde bilgi kaybına neden olur. Bu nedenle, eksik verileri doğru bir şekilde işlemek çok önemlidir.

Veri Dengeleme

Veri setindeki çıktı özelliklerinin (karar değişkenlerinin) eşit dağılmadığı durumlar, veri setinin dengesiz olduğunu gösterir. Gerçek dünyadaki veri setleri genellikle

dengelessizdir ^[22] . Dengesiz veri kümelerinde, örnek sayısı az olan sınıfa azınlık sınıfı, örnek sayısı fazla olan sınıfa ise çoğunluk sınıfı denir ^[23] . Dengesiz veri kümeleri sınıflandırma sonuçlarını yanıltabilir, bu nedenle yapay zeka çalışmalarında karar değişkeninin kullanılan veri kümelerinde eşit olarak dağılması arzu edilir. Verilerin ön işleme aşamasında dengesizliği ortadan kaldırmak için uygulanabilecek çeşitli yöntemler bulunmaktadır. Sentetik Azınlık Aşırı Örnekleme Tekniği (SMOTE), bu sorunu çözmek için kullanılabilir yöntemlerden biridir ve bu çalışmada veri dengesizliğini gidermek amacıyla kullanılmıştır.

SMOTE, en tanınmış ve yaygın olarak kullanılan yeniden örnekleme yöntemlerinden biridir. SMOTE, mevcut azınlık sınıfı örnekleri arasında enterpolasyon yaparak yeni yapay azınlık sınıfı örnekleri oluşturur. Sentetik örnekler üretmeye yönelik bu yaklaşım, el yazısı karakter tanıma alanında kullanılan bir teknikten esinlenmiştir. Yöntem, öncelikle her azınlık sınıfı örneği için en yakın k komşuyu bulur; ardından rastgele bir en yakın komşuyu seçer. Daha sonra,

azınlık sınıfı örneği ile en yakın komşusu arasındaki düz segment kullanılarak yeni bir azınlık sınıfı örneği oluşturulur. Bu işlem, her iki sınıfta da eşit sayıda örnek olana kadar tekrarlanır ^[24] .

Bu çalışmada, veri dengeleme, veri setindeki eksik değerler tamamlandıktan sonra SMOTE yöntemi kullanılarak gerçekleştirilmiştir. Bu veri seti, dengeli veri seti olarak adlandırılmıştır. Hayatta kalma çıktı değişkeni için, çıktı örneklem büyüklüğünü dengelemek amacıyla azınlık örneklerinin sayısı %47 oranında artırılarak 121'den 177'ye çıkarılmıştır. Benzer şekilde, ameliyat çıktı değişkeni için de veri setini dengelemek amacıyla azınlık sınıfına ait örneklerin sayısı %48 oranında artırılmış ve sonuçta 180 "evet" ve 180 "hayır" örneği elde edilmiştir.

Yapay Zeka Modelleri

Bu çalışmada, kolik atların ameliyat ve hayatta kalma durumları on beş yapay zeka sınıflandırma yöntemi kullanılarak tahmin edildi. Bu çalışmada kullanılan yapay zeka sınıflandırma algoritmalarının listesi ve kısa açıklamaları *Tablo 2'de* sunulmuştur.

Tablo 2. Bu çalışmada kullanılan AI modelleri

Kategoriler	Model	Kısaltma	Açıklama
Bayes	Bayes Ağı	BN	Bu, olasılık teorisine dayalı bir grafiksel modelleme yaklaşımıdır. Değişkenler arasındaki ilişkileri gösteren bir ağ yapısı kullanır ve tahminlerde bulunmak için Bayes teoreminden yararlanır ^[25] .
	Naif Bayes	NB	Naive Bayes, Bayes teoremi temelinde sınıflandırmalar yapar ve değişkenler arasında bağımsızlık olduğunu varsayar ^[26] .
Fonksiyonlar	Çok Katmanlı Perceptron	MLP	Yapay sinir ağlarının türlerinden biridir. İnsan beyninin çalışma şeklini taklit ederek karmaşık kararlar verir. Tipik olarak gizli ve çıktı katmanlarından oluşur.
	Basit Lojistik	SL	Verileri uygun bir eğriye uyduran ve olasılık dağılımlarını kullanarak giriş özelliklerinin sınıf tahminlerini ifade etme yeteneğine sahip bir sınıflandırma algoritmasıdır.
	Sıralı Minimal Optimizasyon	SMO	SMO, Destek Vektör Makineleri (SVM) temelli bir sınıflandırma algoritmasıdır. Verileri yüksek boyutlu bir uzaya eşler ve bir uyum sağlar. SVM eğitimi hızlandırmak ve optimize etmek amacıyla geliştirilmiştir ^[27] .
Tembel öğrenme algoritmaları	K-NN (K=1)	1NN	K-NN, bir örneği sınıflandırmak için onu en yakın K komşunun sınıflarıyla karşılaştırır. Yeni bir veri noktası geldiğinde, K-NN bu noktaya en yakın K komşuyu hesaplar ve bu komşuların sınıflarını inceleyerek yeni noktanın sınıfını belirler. K değerinin seçimi sınıflandırma sonuçlarını etkileyebileceğinden ^[28] , çalışmada farklı K değerleri (1, 3, 5, 7) test edilmiştir.
	K-NN (K=3)	3NN	
	K-NN (K=5)	5NN	
	K-NN (K=7)	7NN	
Meta-öğrenme algoritmaları	Bagging REP Ağacı	Bagg-Rep	Bagging yönteminde, her bir temel sınıflandırıcı bağımsız olarak eğitilir ve sonuçları birleştirilerek daha güçlü ve istikrarlı bir sınıflandırıcı oluşturulur. Bu, tahmin performansını artırabilir. Her bir temel sınıflandırıcı farklı bir eğitim alt kümesinde eğitildiğinden, Bagging varyansı azaltabilir ve böylece modelin tahmin performansını iyileştirebilir. Bu çalışmada, tahmin performansları REP Tree, Random Forest ve Çok Katmanlı Perceptron temel sınıflandırıcıları kullanılarak test edilmiştir.
	Bagging Random Forest	Bagg-RF	
	Bagging Çok Katmanlı Perceptron	Bagg-MLP	
	Rastgele Komite	RC	Bu, farklı sınıflandırıcıları birleştirerek daha güçlü bir sınıflandırıcı oluşturmayı amaçlayan bir yöntemdir. İlk olarak, veri kümesi rastgele alt örnekleme ile eğitilir. Ardından, her sınıflandırıcı kendi tahminlerini yapar. Son adımda, bu tahminlerin çoğunluğu sonucu elde etmek için kullanılır ^[29] . Bu çalışmada, sınıflandırıcı olarak Rastgele Ağaç kullanılmıştır.
Ağaç tabanlı algoritmalar	Karar Ağacı	DT	Karar ağacı bir ağaç yapısı olarak gösterilir ve her bir iç düğüm bir özellik ile ilişkilendirilir. Veri kümesi bu ağaç yapısı boyunca ilerledikçe, her düğümde bir karar verilir ve veri noktası, ilgili özelliğin değerine göre bir dala yönlendirilir ^[30] . Bu çalışmada, WEKA'da J48 olarak bilinen C4.5 karar ağacı algoritması kullanılmıştır.
	Rastgele Orman	RF	Bu, birden fazla karar ağacını birleştiren bir toplu öğrenme modelidir. Her ağaç, veri kümesinin rastgele bir alt kümesi üzerinde eğitilir ve bu süreç rastgele tekrarlanır. Ardından, her ağaç veri noktalarını sınıflandırır ve bu sınıflandırmaların sonucu çoğunluk oylamasına tabi tutulur ^[30] .

Bu çalışmada R programlama dili ^[31] ve WEKA 3.8.5 (Waikato Bilgi Analizi Ortamı) aracı ^[32] kullanılmıştır. R programlama dili, eksik verilerin doldurulması ve özellik önem puanlarının belirlenmesi için kullanılmıştır. WEKA aracı, veri dengeleme ve sınıflandırma görevleri için kullanılmıştır. Sınıflandırma yöntemlerinin hem eğitim hem de test aşamaları için K-katlı çapraz doğrulama (CV) tekniği kullanılmıştır. Bu teknik, veri setini eşit büyüklükte K alt kümeye böler. K-1 alt küme model eğitimi için kullanılırken, kalan alt küme modelin performansını test etmek için ayrılır. Bu süreç K kez tekrarlanır ve her alt küme test için bir kez kullanılır. K sonucunun ortalaması, sınıflandırma sonuçlarını birleştirmek ve genel performansı değerlendirmek için kullanılır. CV tekniği, model eğitimi ve performans testi için tüm veri setini kullandığı için model performansını tarafsız bir şekilde değerlendirmek açısından çok önemlidir. Bu çalışmada, 10 kat çapraz doğrulama uygulanmıştır.

Modellerin Performansının Ölçülmesi

Çalışmada, cerrahi müdahale ve hayatta kalma konusunda yapay zeka modellerinin tahmin performansını değerlendirmek için Doğruluk (ACC) ve ROC Eğrisi Altındaki Alan (AUC) ölçütleri kullanılmıştır. Doğruluk, doğru şekilde tanımlanan vakaların toplam vaka sayısına oranını ifade eder (Denklem 1). Bu çalışmada doğruluk, cerrahi müdahale ihtiyacını doğru bir şekilde belirleme ve atın hayatta kalma durumunu doğru bir şekilde tanımlama yeteneğini yansıtmaktadır.

$$Accuracy = \frac{Correct\ Predictions}{All\ Predictions} \quad (1)$$

ROC eğrisi, farklı eşik değerlerinde duyarlılık ve özgüllükteki değişimi gösteren bir grafikdir ve AUC, bu eğrinin altındaki alanı ölçer. Yüksek bir AUC değeri, modelin iyi performans gösterdiğini ve doğru sınıflandırma yapabildiğini gösterir ^[33]. AUC, cerrahi müdahale ihtiyacını ve atın hayatta kalma olasılığını doğru bir şekilde tahmin etme yeteneğini değerlendirmek için kullanılmıştır.

Özellik Seçimi

Özellik seçimi, bir veri kümesinden en alakalı ve bilgilendirici özellikleri seçerken, daha az önemli olanları hariç tutmayı içeren bir süreçtir. Böylelikle veri kümesinin boyutları azaltılır, bu da AI modelinin daha hızlı çalışmasına, daha az bellek tüketimine ve analiz sürecinin kolaylaştırılmasına yol açar. Ancak, özellik azaltma sürecinden sonra model performansı her zaman iyileşmeyebilir. Bazı özelliklerin kaldırılması tahmin performansını artırabilirken, bazı durumlarda önemli bilgilerin kaybedilmesi riski de vardır.

Veterinerlik gibi alanlarda veri toplama zorlu ve maliyetli bir süreç olabilir. Daha az veriyle ne kadar doğru tahminler yapılabilirse, o kadar fazla zaman ve maliyet tasarrufu sağlanabilir. Bu çalışmada, biz

Ameliyat ve hayatta kalma değişkenleri için özellik önem puanları hesaplandı. Bu amaçla R programlama dilindeki "importance" işlevini kullandık ^[34]. Bu yöntem, her bir özelliğin önemini ölçer ve bir önem sıralaması sunar. Özellik önemi, her bir özelliğin modelin tahmin performansına katkısını gösteren Gini önem kriterine dayalı olarak hesaplandı. Özellik önem puanlarını hesapladıktan sonra, en az önemli olanlardan başlayarak özellikleri tek tek kaldırarak tahmin performansını ölçtük. Bu süreç, en yüksek tahmin performansını sağlayan özellik grubunu belirledi.

SONUÇ

Bu çalışmada, yüksek doğrulukta tahminler elde etmek için ön işleme ve son işleme adımları uygulandıktan sonra AI modellerinin tahmin performansları analiz edildi. Ön işleme adımında, veri setindeki özellikler dönüştürüldü, eksik değerler işlendi ve veri dengeleme prosedürleri uygulandı. Son işleme adımında ise bir özellik seçimi süreci gerçekleştirildi.

Ameliyat ve hayatta kalma tahminleri için, veri setinin üç farklı versiyonu üzerinde 15 farklı yapay zeka modeli kullanılarak karşılaştırmalı bir performans analizi gerçekleştirildi. Eksik veriler içeren orijinal veri seti (orijinal olarak anılacaktır), eksik değerlerin missForest yöntemi kullanılarak doldurulduğu veri seti (doldurulmuş olarak anılacaktır) ve doldurma işleminden sonra dengelenen veri seti (dengelenmiş olarak anılacaktır), *Tablo 3'te* 15 yapay zeka modelinin tahmin performansı açısından karşılaştırılmıştır.

Elde edilen bulgulara göre, "dengelenmiş" veri setinin hem ameliyat hem de hayatta kalma tahminleri için en yüksek ortalama doğruluğa sahip olduğu sonucuna varılmıştır (sırasıyla %80,76 ve %77,96). Her iki çıktı değişkeni için en düşük ortalama doğruluğa sahip veri seti orijinal veri seti olmuştur (ameliyat için %78,73 ve hayatta kalma için %72,44).

Tablo 3'te sunulan sonuçlara göre, dengelenmiş veri setinin yüksek doğruluk değeri, işlenmiş ve dengelenmiş versiyonun tahminlerin doğruluğunu artırdığını göstermektedir. Bu nedenle, çalışmanın sonraki aşamalarında ilerleyen işlemler için dengelenmiş veri seti kullanılacaktır. Veri setlerinin tahmin performansı üzerindeki etkisini değerlendirirken, tek bir model yerine 15 farklı yapay zeka modelinin ortalamasının kullanılması, başarının modelden bağımsız olduğunu ortaya koymaktadır.

Ayrıca, ameliyat ve hayatta kalma tahminlerinde en başarılı modeli belirlemek için 15 AI modelinin tahmin performansı içsel olarak karşılaştırılmıştır. Dengeli veri seti için ameliyat ve hayatta kalma tahminlerinin doğruluğu *Tablo 3'te* görülebilir ve AUC değerleri *Şekil 2'de* sunulmuştur.

Tablo 3. Ameliyat ve hayatta kalma tahmini için farklı veri kümeleri üzerindeki modellerin doğruluk (%) sonuçları



Model	Ameliyat Tahmini			Hayatta Kalma Tahmini		
	Orijinal Veri Seti	Doldurulmuş Veri Seti	Dengeli Veri Seti	Orijinal Veri Seti	Doldurulmuş Veri Seti	Dengelenmiş Veri Seti
BN	77,59	76,92	75,27	72,57	75,58	79,15
NB	71,57	73,24	73,33	73,57	75,58	78,02
MLP	77,25	76,92	78,61	68,89	70,90	73,23
SL	80,60	80,26	81,66	70,23	70,24	77,46
SMO	79,93	80,60	81,66	69,89	73,24	77,18
1NN	73,24	74,91	79,72	68,56	72,57	78,87
3NN	74,58	75,91	81,11	68,56	75,58	80,00
5NN	77,59	79,59	83,05	68,56	74,25	79,72
7NN	77,59	79,26	82,22	69,23	73,24	80,28
Bagg-Rep	80,94	80,6	81,94	73,57	74,58	76,34
Bagg-RF	82,60	82,94	84,16	78,26	79,26	80,56
Bagg-MLP	80,26	81,93	80,83	73,91	75,25	76,34
RC	83,27	78,59	82,50	76,92	73,91	80,00
DT	81,27	79,59	79,44	77,25	74,58	71,55
RF	82,6	84,28	85,83	76,58	73,25	80,75
Ortalama	78,73	79,04	80,76	72,44	74,13	77,96


Özellik seçimi, veri setindeki özelliklerin tahmin performansı üzerindeki etkisini incelemek ve mümkünse daha az özellik kullanarak daha yüksek doğruluk elde etmek amacıyla gerçekleştirildi. Veri setindeki özelliklerin önem puanları, *önem* fonksiyonu kullanılarak hesaplandı. *Şekil 3* ve *Şekil 4'te*, cerrahi ve hayatta kalma veri setleri için özelliklerin önem puanları ve RF sınıflandırması yoluyla elde edilen tahmin doğruluğu sunulmaktadır.

Şekil 3 incelendiğinde, ameliyat tahmininde en düşük öneme sahip özelliğin *lesion_3* olduğu (Gini indeksi = 0) görülmektedir. En düşük öneme sahip özellikten başlayarak

, özellikler veri kümesinden yinelenmeli olarak çıkarılmış ve RF yöntemi kullanılarak cerrahi tahmini yapılmıştır. Tüm özellikler kullanıldığında cerrahi tahmini %85,83 doğrulukla yapılmış, ancak en düşük öneme sahip 14 özellik veri kümesinden çıkarıldığında tahmin doğruluğu %86,38'e yükselmiştir.

Şekil 4'te görüldüğü gibi, RF yöntemi ile tüm özellikler kullanılarak yapılan hayatta kalma tahmininin doğruluk oranı %80,75'tir. Ancak, veri setinden en az önemli altı özellik çıkarıldığında, tahmin doğruluğu %83,85'e yükselmiştir. Bu sonuçlar,





Şekil 4. Değişkenlerin ve RF tahmin sonuçlarının Hayatta Kalma Veri Seti üzerindeki etkisi

Veri setindeki en az önemli özellikler, hayatta kalma tahmininin performansını artırır.

Bu bulgular, özellik seçiminin ameliyat ve hayatta kalma tahminlerinin doğruluğunu artırdığını ve önemsiz özelliklerin çıkarılmasının model performansını iyileştirebileceğini de göstermektedir. Sonuçlar ayrıca, yapay zeka sınıflandırma problemlerinde daha etkili tahminler yapabilmek için model karmaşıklığını azaltmanın önemini vurgulamaktadır.

TARTIŞMA

Son yıllarda, yapay zeka yöntemleri çeşitli disiplinlerde yaygın olarak kullanılmaya başlanmıştır. Ancak, veterinerlik alanında bu teknolojinin kullanımı geride kalmış ve henüz beklenen popülerliğe ulaşamamıştır [6,35]. Bu alanda yapay zekanın sınırlı kullanımının başlıca nedenlerinden biri, veri setlerinin genellikle özel olması ve erişilebilirliğinin sınırlı olmasıdır. İnsan tıbbında, yapay zeka uzun yıllardır kapsamlı bir şekilde araştırılmaktadır ve kamuya açık birçok veri seti bulunmaktadır. Ancak, araştırmacılar genellikle kendi çalışmalarında hayvanlar üzerinde toplanan verileri kullanmaktadır. Veri setlerinin gizliliği, disiplinler arası çalışmaların gelişmesini engellemekte ve elde edilen sonuçların şeffaflığını ve doğruluğunu kısıtlamaktadır [36]. Veterinerlik alanında daha fazla disiplinler arası çalışma için verilerin kamuya açık olarak paylaşılmasının bir gereklilik olduğuna inanıyoruz.

Bu çalışma, Kaggle'da kamuya açık olan Horse Colic veri setine yapay zeka adımlarını sistematik olarak uygulayarak karşılaştırmalı sonuçlar sunmaktadır. Yıllar önce yayınlanmış olmasına rağmen, Horse Colic veri seti karmaşıklığı nedeniyle henüz kapsamlı bir şekilde incelenmemiştir. Veri seti, 299 atın 27 özelliğine ait verileri içermekte olup, üç tür veriyi (sürekli, ayrık ve nominal) kapsamaktadır. Ayrıca, nispeten yüksek bir eksik değer oranına sahiptir (Tablo 1) ve dengesizdir.

Eksik değerler, gerçek dünyadaki veri setlerinde sık karşılaşılan bir sorundur [37].

Bazı yapay zeka uygulamalarında, belirli araçlar eksik veri içeren veri kümeleri üzerinde model geliştirilmesine izin vermez. WEKA'da ise yapay zeka modelleri eksik örnekler içeren veri kümeleriyle kullanılabilir, ancak eksik örnekler göz ardı edilir. Her iki senaryo da araştırmacılar için zorluklar teşkil etmektedir. Eksik değerlerden kaçınmak, bu alandaki zaten sınırlı olan örnek sayısını daha da azaltır. Ayrıca, özellikle tıbbi veri kümelerinde, yanlış tahminlerden kaçınmak için eksik değerleri doğru bir şekilde tamamlamak çok önemlidir. Bu çalışmanın temel amaçlarından biri, veri kümesindeki eksik değerleri doğru bir şekilde doldurmaktır. Birçok yapay zeka uygulamasında, veri kümesindeki eksik değerler ya göz ardı edilir ya da ortalama değerle değiştirilir. Ancak, eksik değerleri doğru bir şekilde tamamlamak için birkaç başarılı yöntem geliştirilmiştir. Eksik değerlerin yanlış veya eksik bir şekilde ele alınması, yanıltıcı veya güvenilmez sonuçlara yol açabilir. Bu çalışmada, eksik değerleri tamamlamak için daha önce etkinliği kanıtlanmış olan missForest yöntemi kullanılmıştır. Çalışmanın bulguları, tamamlanmış veri setinin, orijinal veri setiyle yapılan tahminlere kıyasla cerrahi ve hayatta kalma tahminlerinde daha başarılı bir doğruluk sağladığını göstermektedir.

Çalışmanın ikincil amacı, dengesiz veriler sorununu ele almaktır. Bunun nedeni, veri seti dengesizliklerini ele almanın tahmin performansını iyileştirmede önemli olmasıdır. Veri dengesizliği sorunları, ölüm gibi nadir olayların veri setlerinde sınırlı sayıda örnek ile temsil edildiği veterinerlik gibi alanlarda ortaya çıkar. Bu dengesizlikler, modelin öğrenme sürecini ve tahmin performansını olumsuz etkiler [38]. Çalışmada veri seti dengesizliğini gidermek için SMOTE yöntemi kullanılmıştır. Dengelenmiş veri setinin tahmin başarısı diğer veri setleriyle (orijinal ve imputasyonlu) karşılaştırıldığında, en yüksek doğruluk oranları dengelenmiş veri setinden elde edilmiştir. Bu sonuçlar, veri dengesizliği sorunlarının dikkatli bir şekilde ele alınmasının ve veri dengeleme yöntemlerinin kullanılmasının model tahminlerinin performansı üzerinde olumlu bir etkiye sahip olduğunu göstermektedir.

Çalışmanın üçüncü ana amacı, cerrahi ve hayatta kalma tahminleri için en etkili yapay zeka modelini belirlemektir. Bu amaçla, 15 farklı model kullanılarak tahminler yapılmıştır. Cerrahi ve hayatta kalma tahminleri için modellerin performansları karşılaştırıldığında, RF yönteminin diğer yöntemlere göre daha başarılı olduğu sonucuna varılmıştır. RF yöntemi, çeşitli sorunların çözümünde başarılı sonuçlar vermiştir. Bu nedenle, RF yöntemi veteriner hekimliğin çeşitli uygulama alanlarında etkili bir seçenek olabilir.

Çalışmanın nihai amacı, veri setindeki daha az özellik ile daha başarılı tahminler yapmaktır. Bunun nedeni, çok sayıda veri seti özelliğinin model karmaşıklığını artırabilmesi ve aşırı uyum riskini yükseltebilmesidir. Bu nedenle,

özellik seçimi, modeli daha basit ve etkili hale getirir. Ayrıca, tıbbi veri toplama zorlu bir süreç olduğundan, daha az özellik ile daha doğru tahminler yapmak veri toplama ve kaynak kullanımı açısından önemlidir. Bu çalışmada, özellik önem puanları RF önemi kullanılarak hesaplanmıştır. Veri setinden önemi düşük özellikler çıkarıldığında, daha az özellik ile daha doğru tahminler yapılabileceği sonucuna varılmıştır (*Şekil 2*). Bu, veteriner hekimlikteki veri analizi ve yapay zeka çalışmalarında dikkate alınması gereken çok önemli bir husustur.

Sonuç olarak, bu çalışma veteriner hekimlikte yapay zeka yöntemlerinin potansiyelini keşfetmek ve bu alandaki önemli zorlukları ele almak amacıyla gerçekleştirilmiştir. Yapay zeka, veteriner hekimlikte de büyük bir potansiyele sahiptir. Ancak, bu alandaki kullanımı hala sınırlıdır ve veri setlerinin özel ve sınırlı erişilebilirliği gibi önemli engellerle karşı karşıyadır. Bu çalışmanın amacı, eksik verileri ele alma, veri dengesizliklerini giderme ve model karmaşıklığını basitleştirme yöntemlerini ortaya koyarak veteriner hekimlikte yapay zeka araştırmalarını geliştirmektir. Gelecekte, kamuya daha erişilebilir veri setlerinin oluşturulması ve paylaşılması, veterinerlik tıbbında yapay zeka yöntemlerinin daha yaygın olarak benimsenmesini teşvik edebilir. Ayrıca, bu alandaki disiplinler arası çalışmalar, hayvan sağlığı ve tedavisine değerli katkılar sağlayabilir.

BEYANLAR

Verilerin ve Materyallerin Erişilebilirliği: Çalışmada kullanılan veri seti şu adresten herkese açık olarak erişilebilir: <https://www.kaggle.com/datasets/uciml/horse-colic>

Finansal Destek: Bu çalışma finansal olarak desteklenmemiştir.

Çıkar Çatışması: Yazar, herhangi bir çıkar çatışması olmadığını beyan etmiştir.

KAYNAKÇA

1. Cihan P, Ozger ZB: Makine öğrenimi tabanlı *in silico* yöntemleri kullanarak SARS-CoV-2 epitoplarını belirlemeye yönelik yeni bir yaklaşım. *Comput Biol Chem*, 98:107688, 2022. DOI: 10.1016/j.compbiolchem.2022.107688
2. Nasir N, Kansal A, Alshaltone O, Barneih F, Sameer M, Shanableh A, Al-Shamma'a A: Makine öğrenimi algoritmaları kullanılarak su kalitesi sınıflandırması. *J Water Process Eng*, 48:102920, 2022. DOI: 10.1016/j.jwpe.2022.102920
3. Cihan P, Ozel H, Ozcan HK: Yapay zeka yöntemleri ile atmosferik partikül maddelerin modellenmesi. *Environ Monit Assess*, 193, 1-15, 2021. DOI: 10.1007/s10661-021-09091-1
4. Tüfekci P: Makine öğrenimi yöntemleri kullanılarak baz yükü çalışan bir kombine çevrim santralının tam yük elektrik güç çıkışının tahmini. *Int J Electr Power Energy Syst*, 60, 126-140, 2014. DOI: 10.1016/j.ijepes.2014.02.027
5. Vinicki K, Ferrari P, Belic M, Turk R: Kedilerde retikülosit yüzdesini belirlemek için evrişimli sinir ağlarının kullanımı. *arXiv*:180304873, 2018. DOI: 10.48550/arXiv.1803.04873
6. Fraiwan MA, Abutarbush SM: Akut karın (kolik) şikayeti ile başvuran atlarda hayatta kalma olasılığını ve ameliyat ihtiyacını tahmin etmek için yapay zeka kullanımı. *J Equine Vet Sci*, 90:102973, 2020. DOI: 10.1016/j.jevs.2020.102973

jevs.2020.102973

7. Hillyer M, Taylor F, French N: 1997 yılında Britanya Adaları'ndaki safkan at eğitim tesislerinde atlarda kolik üzerine kesitsel bir çalışma. *Equine Vet J*, 33 (4): 380-385, 2001. DOI: 10.2746/042516401776249499
8. Topai M, Macit M: Morkaraman koyunlarında vücut ölçümlerinden vücut ağırlığının tahmin edilmesi. *J Appl Anim Res*, 25 (2): 97-100, 2004. DOI: 10.1080/09712119.2004.9706484
9. Müller TR, Solano M, Tsunemi MH: Köpeklerin göğüs röntgen filmlerinde teyit edilmiş plevral efüzyonun saptanmasında yapay zeka yazılımlarının doğruluğu. *Vet Radiol Ultrasound*, 63 (5): 573-579, 2022. DOI: 10.1111/vru.13089
10. Cihan P, Gökçe E, Atakiçi O, Kırmızıgül AH, Erdoğan HM: Yapay zeka yöntemleriyle kuzularda immünooglobulin G tahmini. *Kafkas Univ Vet Fak Derg*, 27 (1): 21-27, 2021. DOI: 10.9775/kvfd.2020.24642
11. Ferrini S, Rollo C, Bellino C, Borriello G, Cagnotti G, Corona C, Di Muro G, Giacobini M, Iulini B, D'Angelo A: Sığırlarda merkezi sinir sisteminin bulaşıcı ve enflamatuar bozukluklarının sahada tanımlanması için makine öğrenimi tabanlı yeni bir web uygulaması. *J Vet Intern Med*, 37 (2): 766-773, 2023. DOI: 10.1111/jvim.16664
12. Costa da Silva RG, Mishra AP, Riggs CM, Doube M: Derin evrişimli sinir ağırları kullanılarak yarış atlarının uzuv radyografilerinin sınıflandırılması. *Vet Rec Open*, 10 (1): e55, 2023. DOI: 10.1002/vro.255
13. Cihan P, Kalipsiz O, Gökçe E: Yenidoğan kuzularda bilgisayar destekli tanı. *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, 26 (2): 385-391, 2020. DOI: 10.5505/pajes.2019.51447
14. Topuz D: Olasılıksal lojistik regresyon analizi ile emzirme dönemi süt verimi tahmini. *Kafkas Üniv Vet Fak Derg*, 27 (5): 547-557, 2021. DOI: 10.9775/kvfd.2020.25171
15. Baydan B, Barıscı N, Unver HM: Hibritleştirilmiş mask R-CNN mimarisi kullanılarak köpek ve kedilerde tibial kırık yerinin belirlenmesi. *Kafkas Üniv Vet Fak Derg*, 27 (3): 347-353, 2021. DOI: 10.9775/kvfd.2021.25486
16. Kumar Y, Koul A, Singla R, Ijaz MF: Hastalık tanısında yapay zeka: Sistemik literatür taraması, sentezleyici çerçeve ve gelecekteki araştırma gündemi. *J Ambient Intell Humaniz Comput*, 14, 8459-8486, 2022. DOI: 10.1007/s12652-021-03612-z
17. Kaggle: At kolik veri kümesi: Bir atın hayatta kalacağını mı yoksa öleceğini mi tahmin edebilir misiniz? <https://www.kaggle.com/datasets/uciml/horse-colic>; Erişim tarihi: 07.07.2023.
18. Kandel S, Heer J, Plaisant C, Kennedy J, Van Ham F, Riche NH, Weaver C, Lee B, Brodbeck D, Buono P: Veri işleme alanındaki araştırma yönleri: Kullanılabilir ve güvenilir veriler için görselleştirmeler ve dönüşümler. *Inf Vis*, 10 (4): 271-288, 2011. DOI: 10.1177/147387161141519
19. Little RJ, Rubin DB: Eksik Verilerle İstatistiksel Analiz. John Wiley & Sons, 2019.
20. Cihan P: Veri kümelerinde eksik değerlerin doldurulmasına yönelik beş yöntemin karşılaştırılması. *Int Sci Voc Stud J*, 2 (2): 80-85, 2018.
21. Cihan P, Kalipsiz O, Gökçe E: Veri madenciliği yöntemleriyle hayvan hastalıklarında teşhis, prognoz ve risk faktörlerinin belirlenmesi. *Doktora Tezi*, Yıldız Teknik Üniversitesi, Fen Bilimleri Enstitüsü, 2018.
22. Cateni S, Colla V, Vannucci M: Gerçek dünya problemlerine yönelik ikili sınıflandırma görevlerinde dengesiz veri kümelerini yeniden örneklemek için bir yöntem. *Neurocomputing*, 135, 32-41, 2014. DOI: 10.1016/j.neucom.2013.05.059
23. Saptono R, Winarno W, Drahati DP: Naive Bayes sınıflandırıcısı (NBC) kullanılarak diyabetik mellitus (DM) hasta verilerinin sınıflandırılmasında yetersiz örnekleme ve aşırı örnekleme tekniklerinin karşılaştırılması. *J Telecommun Electron Comput Eng*, 10, 145-148, 2018.
24. Chawla NV, Bowyer KW, Hall LO, Kegelmeyer WP: SMOTE: Sentetik azınlık aşırı örnekleme tekniği. *J Artif Intell Res*, 16, 321-357, 2002. DOI: 10.1613/jair.953
25. Friedman N, Geiger D, Goldszmidt M: Bayes ağ sınıflandırıcıları. *Mach Learn*, 29, 131-163, 1997. DOI: 10.1023/A:1007465528199
26. Sallam NM, Saleh AI, Arafat Ali H, Abdelsalam MM: Özellik seçimi ve makine öğrenimi teknikleri olarak gri kurt optimizasyonuna dayalı kan hastalıklarının tespiti için verimli bir strateji. *Appl Sci*, 12 (21):10760, 2022. DOI: 10.3390/app122110760
27. Awad M, Khanna R, Awad M, Khanna R: Sınıflandırma için destek vektör makineleri

sınıflandırma için. İçinde, Verimli Öğrenme Makineleri: Mühendisler ve Sistem Tasarımcıları için Teoriler, Kavramlar ve Uygulamalar. 39-66, Apress Open, 2015.

28. Sanlı T, Sıcaküz Ç, Yüregir O: Veri madenciliğinde üç veri kümesinde sınıflandırma algoritmalarının doğruluğunun karşılaştırılması: 20 sınıf örneği. *Int J Eng Sci Technol*, 12 (3): 81-89, 2020. DOI: 10.4314/ijest.v12i3.8

29. Niranjan A, Nutan D, Nitish A, Shenoy PD, Venugopal K: ERCR TV: Oylama kullanarak verimli anomali sınıflandırması için rastgele komite ve rastgele ağaç kümesi. 2018 3Uluslararası Teknoloji Yakınsaması Konferansı (I2CT). 6-8 Nisan, IEEE, 2018.

30. Breiman L: Rastgele ormanlar. *Mach Learn*, 45, 5-32, 2001. DOI: 10.1023/A:1010933404324

31. Venables W SD, R Core Team R-Sürüm 3.0.2'ye Giriş. 2013. <http://cran.r-project.org/doc/manuals/R-intro.pdf>; Erişim tarihi: 03.09.2023.

32. WEKA: Java tabanlı makine öğrenimi yazılımı. <https://www.cs.waikato.ac.nz/ml/weka/>; Erişim tarihi: 05.09.2023.

33. Hajian-Tilaki K: Tıbbi tanı testi değerlendirmesi için alıcı çalışma karakteristiği (ROC) eğrisi analizi

. *Caspian J Intern Med*, 4 (2): 627-635, 2013.

34. LIAW A: Önem: Değişken önem ölçüsünü çıkar. 2020. <https://www.rdocumentation.org/packages/randomForest/versions/4.6-14/topics/importance>; Erişim tarihi: 03.09.2023.

35. Cihan P, Gokce E, Kalipsiz O: Veterinerlik alanında makine öğrenimi uygulamalarına bir derleme. *Kafkas Univ Vet Fak Derg*, 23 (4): 673-680, 2017. DOI: 10.9775/kvfd.2016.17281

36. Appleby RB, Basran PS: Veterinerlikte yapay zeka. *J Am Vet Med Assoc*, 260 (8): 819-824, 2022. DOI: 10.2460/javma.22.03.0093

37. Tran CT, Zhang M, Andreae P, Xue B, Bui LT: Özellik seçimi ve kümeleme kullanarak eksik verilerde sınıflandırma performansının iyileştirilmesi. *Appl Soft Comput*, 73, 848-861, 2018. DOI: 10.1016/j.asoc.2018.09.026

38. Ali H, Salleh MNM, Saedudin R, Hussain K, Mushtaq MF: Veri madenciliğinde dengesiz sınıf sorunları: Bir derleme. *Indones J Electr Eng Comput Sci*, 14 (3): 1560-1571, 2019. DOI: 10.11591/ijeecs.v14.i3.pp1552-1563

